

ប្រឡងពាក់កណ្តាលឆមាស

ឈ្មោះ: មុត រ៉ាវី

ជំនាញ: អភិវឌ្ឍន៍កម្មវិធីកុំព្យូទ័រ និងទូរស័ព្ទដៃ

ជំនាន់ទី ១៦

មុខវិជ្ជា: Machine Learning/AI

ចម្លើយ

១. Machine Learning ត្រូវបានបែងចែកជា ៤ ប្រភេទធំៗ ដូចជា:

- Supervised Learning
- Unsupervised Learning
- Reinforcement Learning

២. វដ្តនៃការធ្វើ Machine Learning

វដ្តមូលដ្ឋានរួមមានជំហានដូចជា:

- Data Collection (ការប្រមូលទិន្នន័យ) ។
- Data Preprocessing (ការរៀបចំ និងសម្អាតទិន្នន័យ) ។
- Data Analysis (ការវិភាគទិន្នន័យ EDA) ។
- Model Training (ការបង្កើត Model) ។
- Model Evaluation (ការវាយតម្លៃ Model) ។
- Model Deployment (ការដាក់ឱ្យប្រើប្រាស់) ។
- Monitoring & Maintenance (ការតាមដាន និងថែទាំ) ។

៣. ឈ្មោះ Algorithms ក្នុង Machine Learning (៥ ឈ្មោះ)

- Linear Regression
- Logistic Regression
- Decision Tree
- K-Nearest Neighbors (KNN)
- K-Means Clustering

៤. Numpy (Numerical Python) គឺជា Library របស់ Python សម្រាប់ធ្វើការជាមួយអារេ (Arrays) ធំៗ និងមានមុខងារគណនាផ្នែកគណិតវិទ្យាកម្រិតខ្ពស់។

ឈ្មោះ Methods ឬ Functions ក្នុង Numpy ១៥ ឈ្មោះ៖

១. np.array()
២. np.zeros()
៣. np.ones()
៤. np.arange()
៥. np.linspace()
៦. np.reshape()
៧. np.dot()
៨. np.sum()
៩. np.mean()
១០. np.median()
១១. np.std()
១២. np.min()
១៣. np.max()
១៤. np.transpose()
១៥. np.concatenate()

៥. ឃ្លាទី១៖

from sklearn.cluster import KMeans៖ ទាញយក (Import) ម៉ូឌុល KMeans ពី Library scikit-learn ដើម្បីយកមកប្រើប្រាស់សម្រាប់ការធ្វើ Clustering ។

import pandas as pd៖ ទាញយក Library pandas ដោយដាក់ឈ្មោះហៅក្រៅថា pd សម្រាប់គ្រប់គ្រង និងវិភាគទិន្នន័យ ។

df=pd.read_csv('customers.csv')៖ អានឯកសារទិន្នន័យប្រភេទ CSV ដែលមានឈ្មោះថា customers.csv រួចរក្សាទុកវាទៅក្នុងបម្រែបម្រួល (Variable) ឈ្មោះ df (DataFrame) ។

print(df)៖ បង្ហាញទិន្នន័យទាំងអស់ដែលបានអានពីឯកសារ CSV នោះនៅលើ Screen ។

ឃ្លាទី២៖

`X=df.drop('CustomerID', axis=1)`៖ លុបជួរឈរ (Column) ដែលមានឈ្មោះថា 'CustomerID' ចេញពី DataFrame df ព្រោះអត្តសញ្ញាណ ID មិនមែនជាលក្ខណៈពិសេស (Feature) សម្រាប់យកទៅបង្កើត Model ឱ្យចងក្រុមឡើយ (`$axis=1$` មានន័យថាធ្វើការទៅលើជួរឈរ)។ លទ្ធផលដែលនៅសល់ត្រូវបានរក្សាទុកក្នុងប្រថាប់ X ។

`print(X)`៖ បង្ហាញទិន្នន័យ X ដែលបានលុប Column 'CustomerID' រួចរាល់។

ឃ្លាទី៣៖

`model=KMeans(n_clusters =3, random_state =42)`៖ បង្កើត Object របស់ KMeans Model ដោយកំណត់ចំនួនក្រុមដែលចង់ចងក្រង ៣ ក្រុម (`n_clusters=3`) និងកំណត់ `random_state=42` ដើម្បីធានាថាការរត់កូដនៅពេលក្រោយៗទៀតនឹងផ្តល់លទ្ធផលដដែល (មិនប្រែប្រួលចៃដន្យ) ។

`label=model.fit_predict(X)`៖ បញ្ជូនទិន្នន័យ X ទៅឱ្យ Model ធ្វើការគណនាបែងចែកក្រុមផង និងទាញយកលទ្ធផលនៃក្រុម (Labels ដូចជា \$0, 1, 2\$) មកលាក់ទុកក្នុង Variable ឈ្មោះ label ផង។

`print(label)`៖ បង្ហាញលទ្ធផលក្រុមដែលទស្សន៍ទាយបានសម្រាប់រាល់អតិថិជននីមួយៗ (បង្ហាញជា Array នៃលេខក្រុម) ។

ឃ្លាទី៤៖

`df['Cluster']=label`៖ បង្កើតជួរឈរថ្មីមួយឈ្មោះថា 'Cluster' នៅក្នុង DataFrame df ដើម ដោយដាក់តម្លៃជាលេខក្រុម (label) ដែលទើបនឹងទទួលបានពី Model ។

`print(df)`៖ បង្ហាញទិន្នន័យ df សារជាថ្មី ដែលពេលនេះមានបន្ថែមជួរឈរក្រុមអតិថិជន (Cluster) នៅខាងចុង ។

`df_sort=df.sort_values(by='Cluster')`៖ រៀបចំលំដាប់ដោយទិន្នន័យ (Sort) នៅក្នុង DataFrame ឡើងវិញ ដោយផ្អែកលើតម្លៃនៅក្នុងជួរឈរ 'Cluster' (ពីក្រុមទី 0 ដល់ទី 2) រួចរក្សាទុកក្នុង df_sort biographies។

`print(df_sort)`៖ បង្ហាញទិន្នន័យដែលបានរៀបតាមលំដាប់ក្រុមរួចរាល់ ដើម្បីងាយស្រួលមើលអតិថិជននៅក្នុងក្រុមជាមួយគ្នា ។